

Статистический анализ данных · лекция 1

Организационное

- После лекции в Moodle открыт **тест по данной лекции (лекция №6)** — один тест.
- В **18:15** начинается лекция по методам оптимизации — нужно переключиться в другую комнату (видеоконференцию).
- На **следующем практическом занятии** будет выдан **временной ряд**, по которому нужно:
 - рассчитать индивидуальный индекс;
 - выполнить при необходимости **перебазировку**, **связывание** или **сцепление** ряд индексов;
 - если успеем — рассмотреть **агрегатные индексы**.
- Для подготовки к практике нужно повторить материал лекции, особенно:
 - виды линий тренда и их особенности;
 - тему прогнозирования (к ней вернёмся через ~3 лекции при проверке гипотез и адекватности моделей).

Организационное в лекции также включало предупреждение: на практических занятиях внимательно работать с индексами и обязательно интерпретировать полученные графики.

Тема лекции

Моделирование временных рядов: тренды, сезонные колебания, оценка устойчивости, прогнозирование, индексы и операции с ними.

План лекции

1. Основные виды трендов (параболический, экспоненциальный, гиперболический, логарифмический, логистический).
 2. Графический анализ для распознавания типа тенденции.
 3. Сезонные колебания и индексы сезонности.
 4. Оценка устойчивости временного ряда.
 5. Прогнозирование временных рядов: основные понятия и критерии качества.
 6. Индексы: понятие, классификация, индивидуальные индексы, операции с рядами индексов, агрегатные и средние индексы.
-

1. Тренды (продолжение)

1.1. Параболический тренд (парабола второго порядка)

- Параметр **A** — средний уровень тренда на момент времени / на период.
- Параметр **B** — средний за весь период, т.е. средний годовой прирост.
- Тренд применяется для отображения тенденций, которым свойственно **постоянное ускорение**, т.е. возрастание абсолютных изменений уровней.

- Парабола второго порядка может применяться к процессам, которые на некотором непродолжительном этапе развития имеют **примерно постоянное ускорение** (небольшой прирост уровней).

Основные свойства параболического тренда:

1. Неравные, но равномерно возрастающие или равномерно убывающие абсолютные изменения за равные промежутки времени — главное свойство.
2. Парабола по форме — две ветви: восходящая (увеличение уровней) и нисходящая (уменьшение уровней).
3. Трендом считается **только одна ветвь** — либо восходящая, либо нисходящая. Вторую ветвь строить не нужно.
4. Параболы третьего и более высоких порядков применяются редко, так как сложно найти оценки параметров; обычно используют параболу второго порядка.

1.2. Экспоненциальный тренд

- Основной параметр — **k**, который является **постоянным темпом изменения уровня**.
- Если **k > 1**, тренд с возрастающими уровнями.
- Если **k < 1**, тренд выражает тенденцию замедления уровней.
- Тренд характерен для процессов, развивающихся в среде, где нет ограничений для уровня роста; на практике могут быть ограничения по времени или ресурсам.

Основные свойства:

- Абсолютные изменения уровня тренда пропорциональны самому уровню.
- Уровни тренда представляют собой **геометрическую прогрессию**.
- Экспоненциальный тренд лучше сглаживает данные (является аппроксимирующей кривой), чем линейный. Данный тип тренда есть в Excel.

1.3. Гиперболический тренд

- Уравнение имеет вид гиперболы (в общем виде $y = a + \frac{b}{t}$).
- Основной параметр — **b**.
- Если **b > 0**, тренд выражает тенденцию **замедляющего снижения** уровней.
- Если **b < 0**, наблюдается возрастание с течением времени.

Основные свойства:

- Абсолютный прирост или сокращение уровней сопровождается ускорением абсолютных изменений.
- Показатели не являются постоянными.
- При **b > 0** уровни замедленно уменьшаются, при **b < 0** — возрастают.
- Гиперболический тренд может сильно «грубо» сглаживать данные, поэтому не всегда рекомендуется к использованию.

1.4. Логарифмический тренд

- Используется, если процесс приводит к замедлению роста показателя, но рост при этом не прекращается и не стремится к пределу (в этом случае гиперболическая форма не подходит).
- Параметр **b**:
 - **b > 0** — уровни возрастают с замедлением;
 - **b < 0** — уровень тренда уменьшается также с замедлением.
- Темпы изменения постепенно приближаются к 100%.

- Главное свойство: **абсолютные изменения уровней по модулю всегда уменьшаются со временем.**

Отличие от гиперболического тренда: оба отражают затухающий процесс изменений, но у гиперболы затухание происходит быстро при приближении к конечному пределу, а у логарифмического тренда — гораздо медленнее.

1.5. Логистический тренд

- Подходит для описания процесса, при котором показатели проходят **полный цикл развития**: от начального (нулевого) уровня, затем постепенный рост — сначала медленный, затем ускоренный, потом снова замедление.
 - Логистический тренд можно рассматривать как объединение трёх типов тенденций: параболической, линейной и гиперболической.
 - Уравнение более сложное по сравнению с предыдущими; в нём присутствуют параметры A_0 и A_1 (рассматриваются и больше нуля, и меньше нуля).
 - Чем больше параметр A_1 , который умножается на период времени (t), тем быстрее снижаются уровни.
 - Если диапазон изменения уровня ограничен не нулём и единицей, а любыми значениями ($y_{\min}$), ($y_{\max}$)), формула переписывается с учётом этих границ. Чаще всего на практике диапазон именно произвольный.
-

2. Графический анализ для распознавания типа тенденции

Тип тренда должен соответствовать особенностям наблюдаемого процесса. Для этого используется графический анализ.

Правила построения графиков временных рядов:

1. **Соблюдение масштаба** — самое главное правило. Многие пренебрегают им и затем не могут правильно построить временной ряд.
 2. Временные интервалы откладываются по оси (X) (абсцисс), уровни ряда — по оси (Y) (ординат).
 3. Рекомендуется выбирать масштаб так, чтобы ширина графика была примерно в 1,5 раза больше его высоты.
 4. Если уровни ряда на протяжении всего периода много больше нуля и различаются не более чем на 20–30%, следует обозначить перерыв на оси ординат, чтобы увеличить масштаб (на практике с обработанными данными применяется редко).
 5. Если уровни ряда различаются в десятки, сотни тысяч раз, ось координат следует разместить в логарифмическом масштабе (в данном курсе не используется).
 6. Необходимо строго соблюдать равенство промежутков времени на равных отрезках.
-

3. Сезонные колебания и индексы сезонности

При рассмотрении данных по месяцам иногда обнаруживаются повторяющиеся колебания, которые несущественно изменяются, но присутствуют. Периодические колебания с постоянным периодом, равным годовому промежутку, называются **сезонными колебаниями** или **сезонными волнами**. Динамический ряд в этом случае называется **сезонным рядом динамики**.

Методы измерения сезонных колебаний (4 группы):

1. Методы, основанные на применении **средней арифметической**.
2. Методы, основанные на применении **относительных величин**.
3. Методы, основанные на применении **механического выравнивания** (прошлая лекция).
4. Методы, основанные на применении **аналитического выравнивания**.

Сезонные колебания характеризуются **индексами сезонности**. Совокупность этих показателей отражает сезонную волну.

Индекс сезонности — процентное отношение фактических уровней внутренних (например, годовых) к постоянной или переменной средней.

Упрощённая формула: $I_s = \frac{\bar{y}_i}{\bar{y}} \cdot 100\%$ где $\bar{y}_i$ — средняя величина уровня для каждого периода, $\bar{y}$ — общее среднее значение за период наблюдения.

В общем виде формула может записываться иначе, но суть та же.

Коэффициент сезонности позволяет сопоставить величины сезонных колебаний по различным периодам. В формуле используются:

- (i) — индекс сезонности для каждого периода (день, неделя, месяц, квартал);
- (n) — число таких периодов.

4. Устойчивость временного ряда

Устойчивость — важное понятие, которое будет использоваться и дальше.

4.1. Простейшая оценка устойчивости

Самая простая оценка — **размах колебливости** (размах вариации). Также в качестве оценки устойчивости используется отношение средних уровней за благоприятные периоды к средним уровням за неблагоприятные периоды: $K = \frac{\bar{y}_{\text{благ}}}{\bar{y}_{\text{неблаг}}}$

4.2. Абсолютные показатели

Обобщающие абсолютные показатели — отклонения фактических уровней от тренда:

- среднее линейное отклонение;
- среднеквадратическое отклонение.

Среднеквадратическое отклонение часто называют **точностью модели**. При построении любой модели в первую очередь интересуются её точностью и адекватностью.

Также рассчитываются:

- коэффициент линейной колеблемости;
- коэффициент роста колеблемостей;
- коэффициент устойчивости.

Пример: если коэффициент колеблемости составил 10%, то коэффициент устойчивости равен (100% - 10% = 90%). Это означает, что среднее колебание относительно среднего уровня составит 10%. При этом вероятность

того, что конкретное колебание не превысит среднеквадратическое отклонение, будет меньше 100%, даже если распределение колебаний близко к нормальному.

4.3. Ранговый коэффициент Спирмена

Для оценки устойчивости тенденции динамики используется **ранговый коэффициент Спирмена**. Он рассчитывается по формуле с разностью рангов (Δ).

Порядок расчёта:

- пронумеровать периоды времени и уровни ряда в порядке возрастания (присвоить ранги 1, 2, 3, ...);
- вычислить разности рангов.

Коэффициент принимает значения по абсолютной величине от 0 до 1:

- **+1** — ранги уровней совпадают, при росте номеров периодов растут ранги уровней — наблюдается устойчивость;
- **-1** — устойчивое снижение показателей;
- реальные значения находятся между этими крайними значениями.

Для оценки устойчивости тенденции также используется **индекс корреляции** (подробнее будет при изучении корреляционного анализа).

5. Прогнозирование временных рядов

5.1. Основные понятия

- **Долгосрочный прогноз** — прогноз более чем на 5% от объёма наблюдений.
- Качество модели прогнозирования оценивается на основе **остаточных компонентов** ($\sqrt{\text{var}\epsilon_t}$).
- Критерии качества делятся на **критерии точности** и **критерии адекватности** (подробно рассматриваются на лекции 3).

5.2. Критерии оценки прогноза

Используются следующие показатели:

- среднее абсолютное отклонение;
- среднеквадратическая ошибка;
- максимальное абсолютное отклонение;
- средние процентные ошибки.

5.3. Когда следует использовать прогнозирование временных рядов

- Ретроспективные (исторические) данные последовательны и надёжны.
- В данных присутствуют временные закономерности и тенденции.
- Будущее поведение зависит от прошлых наблюдений.
- Прогноз должен быть точным (ошибка не более 1–2%), как, например, прогноз погоды на 1–3 дня.

5.4. Когда прогнозирование временных рядов избегают

- «Грязные» данные: зашумлённые, со всплесками, пропусками, нестабильные.
- В исторических данных нет значимых закономерностей.
- Ключевые факторы влияния неизвестны, не поддаются объяснению или непредсказуемы.

5.5. Алгоритмы прогнозирования временных рядов

- Ансамблевые модели (например, **случайный лес**).
- Модели на основе **свёрточных нейронных сетей**.
- **Скрытые марковские модели**.

С этими алгоритмами студенты подробнее познакомятся на следующих курсах (системы искусственного интеллекта).

6. Индексы

6.1. Понятие и классификация

Индекс — простое и удобное средство сравнения данных между собой.

Пример: за неделю курс доллара вырос с 4 до 5 рублей за доллар (разница 1 рубль). В другом случае — с 4000 до 4100 рублей за доллар. В обоих случаях разница формально составляет 1 рубль, но в процентном выражении это 25% и 0,25% соответственно.

Классификация индексов:

- **По степени охвата элементов:** индивидуальные и сводные.
- **По составу явления:** фиксированного состава, переменного состава, структурных сдвигов.
- **По способу исчисления:** агрегатные и средневзвешенные.
- **По базе сравнения:** динамические, территориальные, цепные, базисные.

6.2. Индивидуальные индексы

Пусть имеется упорядоченный набор данных (временной ряд). Выбирается одно из значений, которое называется **базисным**, обозначается (C) (константа базового периода). Все остальные данные выражаются в процентах к (C). Эта операция называется **индексацией**.

Формула индивидуального индекса: $I = \frac{\text{исходное значение ряда}}{C} \cdot 100\%$

Пример: индексы оптовых цен и объемов производства яблок в США за 1960–1969 гг. Для каждого года вычисляются индексы цен (I_P) и объемов производства (I_Q), которые сводятся в таблицу. Графики индексов строятся для наглядности.

Интерпретация графика: рост объемов производства приводит к падению оптовых цен, и наоборот — при падении объемов цены растут. Полученный график обязательно нужно интерпретировать и делать вывод.

Построить в одной системе координат два ряда разной размерности невозможно, поэтому графики индексных рядов строятся отдельно.

6.3. Трудности при работе с индексами. Операции с рядами индексов

Ряды индексов невозможно сравнивать, если они построены с использованием **разных базисных лет**. Тогда применяются специальные операции.

6.3.1. Перебазировка

Пересчёт рядов к общему базисному году. Например, если для признаков А и В базисными являются разные годы, то ряд признака В пересчитывается на базисный год признака А (например, на 1960 год). После этого ряды можно сравнивать напрямую.

6.3.2. Связывание

Объединение двух рядов индексов для одного признака, имеющих **разные базисные годы**, в единый ряд. Недостающие значения (например, для 1966 и 1968 годов) находятся из соотношений с уже известными индексами. В результате получается полный ряд.

6.3.3. Сцепление

Перебазировка на **скользящий базис**: каждый предыдущий год, для которого уже построен индекс, последовательно принимается за базисный для расчёта очередного года. В результате получается ряд индексов после сцепления.

6.4. Агрегатные индексы

Агрегатные индексы вычисляются сразу по **нескольким временным рядам**:

- каждый ряд умножается на некоторый **вес** (W);
- для каждого момента времени произведения суммируются;
- полученный ряд сумм индексируется по формуле индивидуального индекса.

Результат — результирующий ряд индексов.

6.5. Средние индексы

Средний индекс вычисляется по нескольким индивидуальным индексным рядам:

- каждый индивидуальный ряд умножается на некоторый вес;
- сумма всех произведений для каждого значения делится на сумму весов.

Формула имеет вид: $I = \frac{\sum I_i \cdot W_i}{\sum W_i}$

Выводы по лекции

1. Для описания тенденций временных рядов используются различные виды трендов: параболический, экспоненциальный, гиперболический, логарифмический, логистический. Каждый имеет свои свойства и область применения.
2. Графический метод — важный инструмент предварительного распознавания типа тенденции; необходимо соблюдать правила построения графиков (масштаб, оси, равные интервалы).

3. Сезонные колебания измеряются индексами сезонности; для их сопоставления используется коэффициент сезонности.
 4. Устойчивость временного ряда оценивается размахом, отношением средних уровней благоприятных и неблагоприятных периодов, отклонениями от тренда, а также ранговым коэффициентом Спирмена.
 5. Прогнозирование временных рядов возможно при наличии надёжных данных и устойчивых закономерностей; качество прогноза оценивается по остаточным компонентам и специальным критериям точности.
 6. Индексы — удобное средство сравнения данных. Важно уметь выполнять перебазировку, связывание и сцепление рядов индексов, а также вычислять агрегатные и средние индексы.
-

Вопросы к зачёту / экзамену

1. Основные виды трендов: уравнения, свойства, условия применения.
2. Графический анализ временных рядов: правила построения и распознавание тенденции.
3. Сезонные колебания: понятие, индекс сезонности, коэффициент сезонности.
4. Устойчивость временного ряда: показатели оценки, коэффициент Спирмена.
5. Прогнозирование временных рядов: критерии качества, область применения.
6. Индивидуальные индексы: понятие, формула, пример.
7. Операции с рядами индексов: перебазировка, связывание, сцепление.
8. Агрегатные и средние индексы: назначение и способы расчёта.