

Статистический анализ данных · лекция 1

Организационное

В лекции упоминалось:

- После лекции в Moodle открыт **тест по данной лекции (лекция №6)** – один тест.
 - В **18:15** нужно переключиться в другую комнату на лекцию по методам оптимизации.
 - По теме индексов сезонности будет **практическое занятие или лабораторная работа** (преподаватель точно не уточнил).
 - К следующему практическому занятию нужно повторить материал по **индивидуальным индексам, перебазировке, связыванию, сцеплению, агрегатным индексам** – будет расчётная работа по вариантам.
 - Рекомендуется внимательно разобрать тему **моделирования и прогнозирования** временных рядов: к ней вернутся примерно через 3 лекции (проверка адекватности моделей, критерии точности).
-

Тема лекции

Статистический анализ данных. Моделирование, прогнозирование временных рядов и индексы.

План лекции

1. Моделирование временных рядов: основные виды трендов.
 2. Графический анализ для распознавания типа тенденции.
 3. Сезонные колебания и индексы сезонности.
 4. Устойчивость временного ряда и её показатели.
 5. Прогнозирование временных рядов.
 6. Индексы: индивидуальные, агрегатные, средние; операции с рядами индексов.
-

1. Моделирование временных рядов: тренды

Линейный тренд

Уравнение имеет вид:

$$\hat{y}_t = a + bt,$$

где:

- a – средний уровень тренда на момент времени (начальный уровень);
- b – средний за весь период, т.е. средний годовой прирост.

Линейный тренд применяется для отображения тенденций с примерно постоянным абсолютным изменением уровней.

Парабола второго порядка

$$\hat{y}_t = a + bt + ct^2.$$

Применяется для процессов, которые на некотором непродолжительном этапе развития имеют примерно постоянное ускорение.

Основные свойства:

- Неравные, но равномерно возрастающие или убывающие абсолютные изменения за равные промежутки времени.
- Парабола имеет две ветви (восходящую и нисходящую), но в тренде рассматривают только одну ветвь – либо восходящую, либо нисходящую.
- Параболы более высоких порядков (третьего и т.д.) применяются редко из-за сложности оценивания параметров.

Экспоненциальный тренд

$$\hat{y}_t = a \cdot k^t.$$

Основной параметр k – постоянный темп изменения уровня.

- Если $k > 1$ – тренд с возрастающими уровнями.
- Если $k < 1$ – тренд с замедлением уровней.

Характерен для процессов, развивающихся в среде без ограничений для роста. Свойства:

- абсолютные изменения уровня тренда пропорциональны самим уровням;
- уровни тренда образуют геометрическую прогрессию.

Гиперболический тренд

$$\hat{y}_t = a + \frac{b}{t}.$$

- Если $b > 0$ – тренд выражает тенденцию замедляющегося снижения уровней.
- Если $b < 0$ – наблюдается возрастание с течением времени.

Свойства: абсолютные приросты или сокращения уровней непостоянны, происходит ускорение абсолютных изменений. Используется осторожно, так как грубо сглаживает данные.

Логарифмический тренд

$$\hat{y}_t = a + b \ln t.$$

Применяется, когда процесс замедляется, но рост не прекращается и не стремится к пределу (в отличие от гиперболического тренда).

- Если $b > 0$ – уровни возрастают с замедлением.
- Если $b < 0$ – уровни уменьшаются с замедлением.

Свойства:

- темпы изменения постепенно приближаются к 100%;
- абсолютные изменения уровней по модулю всегда уменьшаются со временем.

Логистический тренд

Описывает процесс, проходящий полный цикл развития: от начального (нулевого) уровня, сначала медленно, затем с ускорением. Логистический тренд объединяет свойства параболического, линейного и гиперболического трендов.

Уравнение содержит параметры A_0 и A_1 (могут быть больше или меньше нуля); A_1 умножается на период времени t . Чем больше A_1 , тем быстрее снижаются уровни. Если диапазон изменения уровня ограничен значениями $y_{\min}$ и $y_{\max}$ (а не нулём и единицей), формула переписывается с учётом этих границ.

2. Графический анализ для распознавания типа тенденции

Тип тренда должен соответствовать особенностям наблюдаемого процесса. Для выбора типа тенденции используется графический анализ.

Правила построения графиков:

1. Соблюдение масштаба (часто игнорируется, но важно для правильного отображения).
 2. Временные интервалы откладываются по оси абсцисс (OX), уровни ряда – по оси ординат (OY).
 3. Ширина графика должна быть примерно в 1,5 раза больше его высоты.
 4. Если уровни ряда много больше нуля и различаются не более чем на 20–30%, можно сделать перерыв на оси ординат (увеличить масштаб).
 5. Если уровни различаются в десятки, сотни, тысячи раз, ось координат размещают в логарифмическом масштабе.
 6. Строго соблюдать равенство промежутков времени на равных отрезках.
-

3. Сезонные колебания и индексы сезонности

Периодические колебания с постоянным периодом, равным годовому промежутку, называются **сезонными колебаниями** (сезонными волнами). Ряд с такими колебаниями – **сезонный ряд динамики**.

Методы измерения сезонных колебаний делятся на четыре группы:

1. Методы, основанные на применении средней арифметической.
2. Методы, основанные на применении относительных величин.
3. Методы, основанные на механическом выравнивании.
4. Методы, основанные на аналитическом выравнивании.

Для характеристики сезонных колебаний используются **индексы сезонности**. Индексы сезонности – это процентные соотношения фактических уровней (например, годовых) к постоянной или переменной средней.

Индекс сезонности для каждого периода:

$$I_i = \frac{\bar{y}_i}{\bar{y}_{\text{общ}}} \cdot 100\%,$$

где $\bar{y}_i$ – средняя величина уровня для каждого периода (день, неделя, месяц, квартал), $\bar{y}_{\text{общ}}$ – общее среднее значение за весь период наблюдения.

Для сопоставления величин сезонных колебаний по разным периодам рассчитывается **коэффициент сезонности**:

$$V_s = \sqrt{\frac{\sum_{i=1}^n (I_i - \bar{I})^2}{n}},$$

где I_i – индекс сезонности для каждого периода, n – число периодов.

4. Устойчивость временного ряда

Простейшая оценка устойчивости уровней временного ряда – **размах колеблемости** (размах вариации, ранее изученный).

В качестве оценки устойчивости может использоваться соотношение средних уровней за благоприятные и неблагоприятные периоды:

$$K_{\text{уст}} = \frac{\bar{y}_{\text{благ}}}{\bar{y}_{\text{небл}}},$$

где $\bar{y}_{\text{благ}}$ – средний уровень за благоприятные периоды, $\bar{y}_{\text{небл}}$ – средний уровень за неблагоприятные периоды.

Обобщающие абсолютные показатели – отклонения фактических уровней от тренда:

- среднелинейное отклонение;
- среднеквадратическое отклонение.

Среднее квадратическое отклонение часто называют **точностью модели**.

На основе этих показателей рассчитываются:

- коэффициент линейной колеблемости;
- коэффициент колеблемости;
- коэффициент устойчивости.

Если коэффициент колеблемости равен, например, 10%, то коэффициент устойчивости равен $100\% - 10\% = 90\%$. Это означает, что среднее колебание относительно среднего уровня составит 10%, но вероятность того, что конкретное колебание не превысит среднеквадратическое отклонение, будет меньше 100% (при распределении, близком к нормальному).

Ранговый коэффициент Спирмена

Используется для оценки устойчивости тенденции динамики. Это ранговый коэффициент, формула основана на разности рангов:

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)},$$

где d_i – разность рангов (периоды времени и уровни ряда нумеруются в порядке возрастания).

Значения коэффициента r_s находятся в пределах от -1 до $+1$:

- $r_s = +1$ – ранги уровней совпадают с номерами периодов, наблюдается устойчивый рост;
- $r_s = -1$ – устойчивое снижение показателей;
- промежуточные значения – разная степень устойчивости.

Для оценки устойчивости тенденции также используется индекс корреляции (будет подробно рассматриваться в теме корреляционного анализа).

5. Прогнозирование временных рядов

Прогнозы делятся на:

- краткосрочные;
- среднесрочные;
- долгосрочные (прогноз более чем на 5% от объёма наблюдений).

Качество модели прогнозирования оценивается на основе **остаточных компонентов** ε_t . Выделяют критерии точности и критерии адекватности модели (будут подробно рассматриваться позже, примерно через 3 лекции).

Критерии оценки прогноза:

- среднее абсолютное отклонение;
- средняя квадратическая ошибка;
- максимальное абсолютное отклонение;
- средние процентные ошибки.

Когда следует использовать прогнозирование временных рядов:

- ретроспективные (исторические) данные последовательны и надёжны;
- в данных присутствуют временные закономерности и тенденции;
- будущее поведение зависит от прошлых наблюдений.

Когда прогнозирование избегают:

- данные «грязные» (зашумлены, есть всплески, пропуски, нестабильны);
- в исторических данных нет значимых закономерностей;
- ключевые факторы влияния неизвестны, необъяснимы или непредсказуемы.

Алгоритмы прогнозирования временных рядов:

- ансамблевая модель;
- случайный лес;
- модели на основе свёрточных нейронных сетей;
- скрытые марковские модели.

Подробнее эти алгоритмы рассматриваются в следующих семестрах (например, в курсе «Системы искусственного интеллекта»).

6. Индексы

Понятие индекса

Индекс – простое и удобное средство сравнения данных. Пример: курс доллара вырос с 4 до 5 рублей (разница 1 рубль) и с 4000 до 4001 рубля (разница также 1 рубль). В процентах это 25% и 0,25% соответственно.

Классификация индексов

По степени охвата элементов:

- **индивидуальные** – характеризуют изменение одного элемента совокупности;
- **сводные** – характеризуют сложные явления.

По способу исчисления:

- агрегатные;
- среднеарифметические (средневзвешенные).

По составу явления:

- фиксированного (постоянного) состава;
- переменного состава;
- структурных сдвигов.

По базе сравнения:

- динамические (изменение во времени);
- территориальные (межрегиональные сравнения);
- цепные и базисные.

Индивидуальный индекс

Пусть имеется временной ряд. Одно из значений выбирается базовым и обозначается c (константа базового периода). Все остальные данные выражаются в процентах к c – это операция называется **индексацией**.

Индивидуальный индекс:

$$I = \frac{y_t}{c} \cdot 100\%,$$

где y_t – исходное значение временного ряда, c – базовое значение.

Пример. Даны индексы оптовых цен и объёмов производства яблок в США за 1960–1969 гг. (цены – в денежных единицах, объём – Q). По формуле выше для каждого года находятся индексы I_Q и I_P . Результаты сводятся в таблицу и могут быть представлены в виде графиков. По графику видно: рост объёмов производства ведёт к падению оптовых цен, и наоборот. График обязательно нужно интерпретировать (делать вывод).

Построить в одной системе координат два ряда разных размерностей невозможно, поэтому строятся отдельные графики индексных рядов.

Трудности при вычислениях с индексами и операции с рядами индексов

Ряды индексов часто невозможно сравнить, если при их построении использовались разные базисные годы. Для решения этой проблемы применяются специальные операции.

Перебазировка

Имеются два ряда индексов с разными базисными годами. Один из рядов пересчитывается так, чтобы базисный год совпал с базисным годом другого ряда. Например, если для признака А базисный – 60-й год, а для признака В – 50-й, то индексы признака В пересчитываются на 60-й год. После этого ряды можно сравнивать.

Связывание

Имеются два ряда индексов для одного и того же признака, но с разными базисными периодами, причём один ряд продолжает другой во времени. Для получения единого ряда находят недостающие значения через пропорции (составляются соотношения индексов в перекрывающийся период). В результате получается полный ряд индексов за весь период.

Сцепление

Имеется ряд индексов, который нужно перебазировать на **скользящий базис**: каждый предшествующий год, для которого индекс уже есть, последовательно принимается за базисный для расчёта очередного года. После преобразования получается ряд индексов, отражающих изменение к предыдущему периоду.

Агрегатные индексы

Агрегатные индексы вычисляются по нескольким временным рядам одновременно. Каждый ряд умножается на некоторый вес W , затем произведения суммируются для каждого момента времени:

$$Y_t = \sum_i W_i \cdot y_{i,t}.$$

Ряд сумм Y_t затем индексируется по формуле индивидуального индекса (к базовому значению):

$$I_t = \frac{Y_t}{Y_{\text{баз}}} \cdot 100\%.$$

Средний индекс

Вычисляется по нескольким индивидуальным индексным рядам с весами:

$$I_{\text{ср}} = \frac{\sum_i I_i \cdot W_i}{\sum_i W_i},$$

где I_i – индивидуальные индексы, W_i – веса.

Выводы по лекции

- Моделирование временных рядов основано на подборе тренда: линейного, параболического, экспоненциального, гиперболического, логарифмического, логистического. Каждый тренд имеет свои

свойства и область применения.

- Для выбора типа тренда используется графический анализ с соблюдением правил построения.
 - Сезонные колебания измеряются индексами сезонности и коэффициентом сезонности.
 - Устойчивость временного ряда оценивается через размах, средние отклонения, коэффициенты колеблемости и устойчивости, а также ранговый коэффициент Спирмана.
 - Прогнозирование временных рядов требует оценки качества моделей по остаточным компонентам и критериям точности/адекватности.
 - Индексы – средство сравнения данных. Индивидуальные индексы позволяют анализировать изменение одного показателя; агрегатные и средние индексы – обобщать несколько рядов. Для сопоставимости рядов индексов выполняются перебазировка, связывание, сцепление.
-

Вопросы для подготовки к зачёту (по материалам лекции)

1. Перечислите основные виды трендов и охарактеризуйте свойства каждого из них.
2. В каких случаях применяется парабола второго порядка? Почему обычно используют только одну ветвь параболы?
3. Что такое экспоненциальный тренд? Как параметр k влияет на динамику уровней?
4. Чем отличается гиперболический тренд от логарифмического?
5. Что такое логистический тренд и для описания каких процессов он используется?
6. Какие правила построения графиков временных рядов необходимо соблюдать?
7. Что такое сезонные колебания и как они измеряются?
8. Как рассчитывается индекс сезонности и коэффициент сезонности?
9. Что такое устойчивость временного ряда? Назовите основные показатели устойчивости.
10. Как вычисляется ранговый коэффициент Спирмана и что означают его значения?
11. Какие виды прогнозов существуют? В каких случаях целесообразно прогнозирование временных рядов?
12. Назовите критерии оценки качества прогнозных моделей.
13. Приведите классификацию индексов.
14. Что такое индивидуальный индекс? Приведите формулу.
15. Для чего нужны операции перебазировки, связывания и сцепления рядов индексов?
16. Как строятся агрегатные и средние индексы?